



UNIVERSIDADE FEDERAL DE SÃO CARLOS

DEPARTAMENTO DE COMPUTAÇÃO

PROCESSAMENTO DE LINGUAGEM NATURAL

Deteccção Automática de Fake News em Português Brasileiro

DOCENTE RESPONSÁVEL: Helena Caseli

DISCENTES:

Bruno Nieri Nunes - 820590

Gabriel Lucchetta Garcia Sanchez - 828513

Gustavo Kim Alcantara - 820763

Pietro Bernardo Dutra Scaglione - 824375

Samuel Gerga Martins - 821772

Renato Dias Ferreira Campos - 821328

SÃO CARLOS – SP

Maio, 2026

1. Tarefa Escolhida

A tarefa escolhida para este projeto é a detecção automática de fake news em português brasileiro. O objetivo consiste em desenvolver um sistema capaz de classificar notícias como falsas ou verdadeiras a partir da análise de seu conteúdo textual.

A disseminação de notícias falsas representa um problema significativo na sociedade contemporânea, especialmente em contextos relacionados à política, saúde pública e economia. Informações incorretas podem influenciar decisões individuais e coletivas, comprometer a confiança em instituições e gerar impactos sociais relevantes. Nesse contexto, técnicas de Processamento de Linguagem Natural (PLN) podem ser empregadas para automatizar a identificação desse tipo de conteúdo.

Do ponto de vista computacional, trata-se de uma tarefa de classificação de textos, na qual cada documento recebe uma das duas classes possíveis: fake (notícia falsa) ou true (notícia verdadeira). O sistema deverá analisar características linguísticas, estruturais e estatísticas do texto para realizar essa distinção.

Exemplo de classificação:

- "Vacina contra COVID-19 altera o DNA humano", classificada como fake.
- "Banco Central anuncia nova taxa básica de juros", classificada como true.

A escolha dessa tarefa se justifica por sua relevância social, pela disponibilidade de corpora em português brasileiro e pela ampla utilização do problema na literatura científica de PLN e aprendizado de máquina.

2. Dataset que Será Utilizado

O dataset selecionado para este projeto é o Fake.Br Corpus, um conjunto de dados desenvolvido para pesquisas em detecção automática de fake news em português brasileiro. O corpus foi criado por pesquisadores brasileiros vinculados ao NILC (Núcleo Interinstitucional de Linguística Computacional) e à Universidade de São Paulo (USP).

2.1 Repositório Oficial

- Disponível em: <https://github.com/roneysco/Fake.br-Corpus>

2.2 Estrutura do Dataset

O corpus possui um total de **7.200 notícias**, distribuídas igualmente entre as duas classes do problema:

- 3.600 notícias falsas (*fake news*);
- 3.600 notícias verdadeiras (*true news*).

Trata-se, portanto, de um conjunto de dados balanceados, o que favorece o treinamento e a avaliação de modelos de classificação.

Cada notícia contém informações como:

- título;
- texto completo;
- rótulo da classe (*fake* ou *true*);
- metadados adicionais.

2.3 Formato dos Dados

Os textos pertencem a diferentes domínios, incluindo política, economia, saúde e cotidiano, proporcionando diversidade temática e maior robustez aos experimentos.

- **Full Texts:** A pasta `full_texts` contém os textos completos das notícias conforme coletados originalmente dos respectivos sites(*fake*, *true*, metadados *fake* e *true*)
- **Metadados:** Os arquivos de metadados contém informações adicionais sobre cada notícia, como autor, link, categoria, data de publicação e diversos atributos linguísticos, incluindo quantidade de palavras, verbos, substantivos, tamanho médio das sentenças e diversidade lexical.
- **Size Normalized Texts:** A pasta `size_normalized_texts` contém versões normalizadas das notícias, em que textos maiores foram truncados para possuir tamanho semelhante ao texto correspondente, reduzindo possíveis vieses relacionados ao comprimento dos documentos.
- **Preprocessed:** A pasta `preprocessed` disponibiliza uma versão pré-processada do corpus em formato CSV, contendo os textos normalizados, remoção de stopwords, acentuação e caracteres especiais, facilitando a aplicação de técnicas de PLN e aprendizado de máquina.

2.4 Características Gerais do Dataset

- Idioma: português brasileiro;
- Tipo de texto: notícias jornalísticas;
- Número de classes: 2 (*fake* e *true*);
- Tamanho total: 7.200 documentos;
- Quantidade de notícias falsas: 3.600;
- Quantidade de notícias verdadeiras: 3.600;
- Distribuição balanceada entre as classes;
- Formato dos arquivos: **.txt** e **.csv**;
- Domínios temáticos: política, economia, saúde e cotidiano;
- Disponibilidade de metadados linguísticos e estatísticos;
- Disponibilidade de versões pré-processadas e normalizadas dos textos.

3. Possíveis Estratégias a Serem Investigadas

Estratégia 1: Sistema Baseado em Regras Heurísticas

A ideia central é construir um sistema interpretável, baseado em características linguísticas e estilísticas conhecidas na literatura como indicadores de desinformação.

Características de nível superficial (léxico e ortografia):

- Proporção de letras maiúsculas no título e no corpo do texto: textos sensacionalistas tendem a abusar de caixa alta;
- Densidade de pontuação expressiva (!, ?, ...): fake news frequentemente apelam à emoção;
- Presença de palavras com ortografia informal ou erros gramaticais: indicativo de produção descuidada;
- Uso de emojis ou linguagem típica de redes sociais no texto noticioso.

Características lexicais e semânticas:

- Listas de termos sensacionalistas em português (ex.: "CHOCANTE", "IMPERDÍVEL", "BOMBA", "URGENTE") construídas manualmente ou extraídas de corpórea anotados;
- Presença de termos de hedging (ex.: "dizem que", "segundo fontes", "ao que tudo indica") sem indicação de fonte verificável;
- Alta frequência de adjetivos e advérbios de intensidade (ex.: "absolutamente", "totalmente", "jamais") comparada com notícias reais;
- Uso de negação dupla ou linguagem ambígua como recurso retórico.

Características estruturais:

- Razão entre o comprimento do título e o comprimento do corpo: títulos longos e corpos curtos são padrão em conteúdo clickbait;
- Ausência de citações diretas ou fontes identificadas no texto;
- Número de parágrafos e estrutura narrativa: notícias falsas tendem a ser menos estruturadas;
- Presença ou ausência de datas, nomes de instituições e localidades específicas.

Sistema de pontuação: Cada característica recebe um peso pré-definido com base em literatura ou ajuste empírico. A soma ponderada das ativações gera um escore final; textos acima de um limiar são classificados como fake. O limiar pode ser ajustado para balancear precisão e recall.

Vantagens: totalmente interpretável, sem necessidade de treinamento, facilmente auditável.

Limitações: não generaliza bem para estilos novos e exige manutenção manual das listas.

Estratégia 2: Aprendizado de Máquina com Representações Vetoriais Clássicas

Esta abordagem transforma o texto em vetores numéricos e treina classificadores supervisionados.

Pré-processamento:

O pipeline textual incluirá as seguintes etapas em sequência:

1. Normalização: conversão para minúsculas, remoção de acentos opcionalmente, normalização de espaços e caracteres especiais;
2. Tokenização: segmentação em tokens com bibliotecas como spaCy (modelo pt_core_news_sm) ou NLTK;
3. Remoção de stopwords: filtragem de termos de alta frequência e baixo conteúdo informativo (ex.: "de", "que", "para") usando listas em português;
4. Lematização: redução das palavras à sua forma canônica (ex.: "correram" → "correr"), preservando mais informação semântica do que o stemming;
5. Stemming (alternativa): redução mais agressiva ao radical (ex.: "correram" → "corr"), útil quando o vocabulário é mais variado.

Representações vetoriais:

- Bag of Words (BoW): representação binária ou por contagem de termos, simples mas eficaz como baseline;
- TF-IDF: pondera cada termo pela sua frequência no documento e raridade no corpus, reduzindo o impacto de palavras muito comuns;
- N-gramas de caracteres e palavras: captura padrões morfológicos (bigramas de caracteres) e colocações frequentes (bigramas/trigramas de palavras), úteis para identificar jargão sensacionalista;
- Embeddings estáticos (Word2Vec / FastText): representações densas treinadas em grandes corpórea em português (ex.: corpus do NILC/USP), combinadas por média ou soma dos vetores de palavras para representar o documento inteiro. O FastText lida melhor com palavras fora do vocabulário por operar em subpalavras.

Algoritmos de classificação:

Algoritmo	Características principais
Naive Bayes Multinomial	Eficiência, baseline bom para BoW/TF-IDF
Regressão Logística	Facilmente interpretável, regularizável(L1,L2), apresenta desempenho sólido em textos
SVM	Apresenta desempenho alto em espaços de

	alta dimensão, como o TF-IDF
Random Forest	É robusto a overfitting e pode capturar relações não lineares
Gradient Boosting (XGboost)	Uma alta performance, mas pode precisar de maiores ajustes em hiperparâmetros

Engenharia de features adicionais: Além das representações textuais, podem ser concatenados ao vetor final features externas como comprimento do texto, proporção de maiúsculas, escore de sensacionalismo, contagem de fontes citadas etc., combinando a Estratégia 1 com a Estratégia 2.

Ajuste de hiperparâmetros: será utilizada busca em grade (*grid search*) com validação cruzada estratificada (k=5 ou k=10) para seleccionar os melhores parâmetros de cada modelo.

Estratégia 3: Modelos de Linguagem Baseados em Transformers (BERTimbau)

A abordagem 3 aproveita modelos pré-treinados com atenção bidirecional para capturar contexto semântico profundo. Será um teste, caso as 2 primeiras implementações estejam 100%

Modelo base: BERTimbau (neuralmind/bert-base-portuguese-cased), pré-treinado em ~2,7 bilhões de palavras em português brasileiro e europeu (cópus BrWaC + Wikipedia PT). Alternativas incluem o mBERT (multilíngue) e o RoBERTa para português.

Procedimento de fine-tuning:

1. Tokenização com WordPiece: o texto é segmentado pelo tokenizador nativo do BERTimbau, que produz subpalavras e adiciona tokens especiais [CLS] e [SEP];
2. Truncagem e padding: textos são limitados a 512 tokens (limite do BERT); textos maiores podem ser divididos em janelas deslizantes com agregação posterior das predições;
3. Cabeça de classificação: sobre a representação do token [CLS] é adicionada uma camada densa com ativação softmax para prever as classes fake / true;
4. Fine-tuning supervisionado: os pesos do modelo são ajustados no dataset Fake.Br com um otimizador AdamW, taxa de aprendizado baixa ($\sim 2e-5$), por 3 a 5 épocas, com early stopping baseado na perda de validação;
5. Regularização: dropout no cabeçalho de classificação e weight decay para prevenir overfitting.

Variações a explorar:

- Fine-tuning apenas na camada de classificação, congelando o encoder (mais rápido, menos dados necessários);
- Fine-tuning completo de todas as camadas (melhor desempenho esperado);

- Uso de [CLS] vs. média de todos os tokens como representação do documento.

Considerações práticas: O treinamento exige GPU; recomenda-se o uso do Google Colab (T4/A100) ou Kaggle Notebooks. A biblioteca transformers da Hugging Face simplifica o carregamento e fine-tuning do BERTimbau.

4. Modo de Avaliação da Tarefa

A avaliação das estratégias investigadas será conduzida em três níveis complementares: avaliação quantitativa por métricas automáticas, análise estrutural dos erros e avaliação qualitativa manual. Essa abordagem multidimensional permite não apenas comparar o desempenho numérico dos modelos, mas também compreender seus comportamentos, limitações e adequação ao problema.

4.1 Divisão do Dataset

Antes de qualquer avaliação, o Fake.Br Corpus será particionado de forma estratificada, garantindo que a proporção entre as classes **fake** e **true** seja preservada em cada subconjunto. A divisão adotada será:

- Treinamento: 70% dos dados (5.040 notícias), utilizados para ajuste dos parâmetros dos modelos;
- Validação: 10% dos dados (720 notícias), utilizados para seleção de hiperparâmetros e early stopping;
- Teste: 20% dos dados (1.440 notícias), reservados exclusivamente para avaliação final e comparação entre estratégias.

O conjunto de teste não será acessado durante o desenvolvimento, sendo utilizado apenas na etapa final de avaliação para evitar vazamento de informação (*data leakage*) e garantir estimativas de desempenho não viesadas.

Para os modelos de aprendizado de máquina clássico (Estratégia 2), será empregada adicionalmente validação cruzada estratificada com $k = 10$ folds sobre o conjunto de treinamento, reduzindo a variância das estimativas de desempenho e aproveitando melhor os dados disponíveis.

4.2 Métricas Quantitativas

Dado que o dataset é balanceado entre as classes, todas as métricas abaixo são aplicáveis sem necessidade de ponderação adicional. Ainda assim, serão reportadas tanto as métricas por classe quanto às médias macro e micro para maior completude.

Acurácia:

A proporção de classificações corretas sobre o total de exemplos. Embora seja a métrica mais intuitiva, ela pode ser enganosa em datasets desbalanceados. No contexto deste projeto, com classes equilibradas, serve como indicador geral confiável.

Precisão:

A proporção de notícias classificadas como fake que são de fato falsas. Alta precisão indica que o modelo raramente rotula notícias verdadeiras como falsas, erro com custo social relevante, pois pode levar à censura indevida de conteúdo legítimo.

Revocação:

A proporção de notícias realmente falsas que foram corretamente identificadas. Alta revocação indica que o modelo raramente deixa passar uma fake news, erro igualmente custoso, pois permite que desinformação circule sem detecção.

F1-score:

Média harmônica entre precisão e recall, penalizando desequilíbrios entre as duas. Será a métrica principal de comparação entre estratégias, por sintetizar o equilíbrio entre os dois tipos de erro.

F-beta (F_β)

Caso desejemos priorizar explicitamente um dos tipos de erro, pode-se usar a medida F_β , que pondera recall β^2 vezes mais que precisão. Por exemplo, com $\beta = 2$, o modelo será avaliado priorizando a detecção de fake news (recall), o que é justificável pelo impacto social do problema.

AUC-ROC:

A Área Sob a Curva ROC (Receiver Operating Characteristic) mede a capacidade do modelo de discriminar as duas classes em diferentes limiares de classificação. Um AUC de 1,0 indica separação perfeita; 0,5 indica classificação aleatória. Essa métrica é especialmente útil para comparar modelos que produzem probabilidades como saída (regressão logística, BERTimbau), pois é independente do limiar de decisão.

Resumo das métricas e suas interpretações:

Métrica	O que penaliza	Quando vamos priorizar
Acurácia	Qualquer erro	Usada para uma visão geral
Precisão	Falsos Positivos	Para evitar censura de conteúdo real

Recall	Falsos Negativos	Evitar propagação de fake news
F1	Desequilíbrio P/R	Comparação geral entre modelos
F _β	Falsos Negativos	Opcional para contextos de alto risco social
AUC-ROC	Ambos os erros limiares	Comparação dos modelos probabilísticos

4.3 Matriz de Confusão e Análise de Erros

A matriz de confusão será construída para cada estratégia avaliada, detalhando as quatro categorias de classificação:

	Predito: É Fake news	Predito: É notícia verdadeira
Real: É fake news	Verdadeiro Positivo	Falso Negativo
Real: É notícia verdadeira	Falso Positivo	Verdadeiro Negativo

A partir dela, serão identificados e analisados separadamente:

- Falsos Negativos: fake news que passaram despercebidas — erro de maior impacto social;
- Falsos Positivos: notícias verdadeiras incorretamente classificadas como falsas, relevante do ponto de vista de confiabilidade do sistema.

A taxa de erro por domínio temático (política, saúde, economia, cotidiano) também será calculada, permitindo identificar se alguma estratégia tem dificuldade sistemática com determinados temas.

4.4 Avaliação Qualitativa Manual

Será selecionada uma amostra aleatória estratificada de 60 notícias do conjunto de teste (15 de cada combinação TP/TN/FP/FN de um modelo de referência), sobre as quais será realizada análise manual por membros do grupo.

O objetivo é responder perguntas como:

- Quais características linguísticas induzem o modelo ao erro?
- Fake news de quais domínios são mais difíceis de detectar automaticamente?
- Há padrões recorrentes nos falsos positivos (ex.: notícias verdadeiras com linguagem informal)?
- Os erros do sistema baseado em regras diferem qualitativamente dos erros do modelo de ML?

Os resultados serão sumarizados em uma tabela de análise de casos, com exemplos representativos anotados.

4.5 Concordância entre Avaliadores (Coeficiente Kappa de Cohen)

Na etapa de avaliação qualitativa manual, cada notícia da amostra será classificada independentemente por dois integrantes do grupo, sem comunicação prévia entre eles. Em seguida, será calculado o Coeficiente Kappa de Cohen (κ) para medir o grau de concordância entre os avaliadores, descontando a concordância esperada por acaso..

Interpretação padrão do κ :

Valor de k	Interpretação
<0,20	Concordância fraca
0,21 >= k <= 0,40	Concordância razoável
0,41 >= k <= 0,60	Concordância moderada
0,61 >= k <= 0,80	Concordância alta
k > 0,80	Concordância quase perfeita

5. Considerações Finais

O presente projeto estrutura uma abordagem sólida e progressiva para o desafio da detecção de *fake news* no contexto do português brasileiro. A adoção do Fake.Br Corpus garante uma base de dados robusta, balanceada e tematicamente diversa, fornecendo os subsídios necessários para o treinamento e a validação adequados dos modelos propostos.

O principal diferencial técnico desta proposta reside na investigação comparativa de três níveis de complexidade algorítmica: o uso de regras heurísticas para garantir máxima interpretabilidade; a aplicação de modelos clássicos de aprendizado de máquina com representação vetorial, buscando um ponto de equilíbrio entre eficiência e performance; e a exploração de modelos de linguagem baseados em *Transformers* (BERTimbau), visando a compreensão do contexto semântico profundo. Essa gradação permite avaliar não apenas o poder preditivo, mas também o custo-benefício computacional e a explicabilidade de cada estratégia frente ao problema.

Por fim, a definição de um *pipeline* de avaliação multidimensional evidencia o rigor analítico do projeto. Ao combinar métricas quantitativas robustas, análise estrutural dos falsos positivos e negativos nas matrizes de confusão, e uma avaliação qualitativa humana validada estatisticamente pelo Coeficiente Kappa de Cohen, o trabalho transcende a simples classificação binária. Espera-se, com isso, mapear as vulnerabilidades linguísticas que induzem os modelos ao erro e entender as limitações práticas dos classificadores, entregando uma contribuição crítica, bem fundamentada e aplicável ao combate à desinformação.

6. Referências

Estratégias que serão investigadas:

- [A Survey on Natural Language Processing for Fake News Detection](<https://aclanthology.org/2020.lrec-1.747/>) (Oshikawa et al., LREC 2020) <https://aclanthology.org/2020.lrec-1.747/>
- SPARCK JONES K (1972), "A STATISTICAL INTERPRETATION OF TERM SPECIFICITY AND ITS APPLICATION IN RETRIEVAL". *Journal of Documentation*, Vol. 28 No. 1 pp. 11–21, doi: <https://doi.org/10.1108/eb026526>
- Piotr Bojanowski, Edouard Grave, Armand Joulin, Tomas Mikolov; Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics* 2017; 5 135–146. doi: https://doi.org/10.1162/tacl_a_00051
- Bojanowski, P., Grave, E., Joulin, A., & Mikolov, T. (2017). *Enriching Word Vectors with Subword Information*. *Transactions of the Association for Computational Linguistics*, 5, 135–146. https://doi.org/10.1162/tacl_a_00051
- Vieira, A. C. et al. (2023). *fakenewsbr: A Fake News Detection Platform for Brazilian Portuguese*. arXiv:2309.11052. <https://arxiv.org/abs/2309.11052>
- Souza, F., Nogueira, R., Lotufo, R. (2020). BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In: Cerri, R., Prati, R.C. (eds) *Intelligent Systems. BRACIS 2020. Lecture Notes in Computer Science()*, vol 12319. Springer, Cham. https://doi.org/10.1007/978-3-030-61377-8_28

Métodos de Avaliação:

- Kohavi, R. (1995). *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*. In: *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI 1995)*, Montreal, pp. 1137–1145. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. Disponível em: <https://nlp.stanford.edu/IR-book/>
- Silva, R. M., Santos, R. L. S., Almeida, T. A., & Pardo, T. A. S. (2020). *Towards automatically filtering fake news in Portuguese*. *Expert Systems with Applications*, 146, 113199. <https://doi.org/10.1016/j.eswa.2020.113199>
- Cohen, J. (1960). *A coefficient of agreement for nominal scales*. *Educational and Psychological Measurement*, 20(1), 37–46. <https://doi.org/10.1177/001316446002000104>
- Landis JR, Koch GG. The measurement of observer agreement for categorical data. *Biometrics*. 1977 Mar;33(1):159-74. PMID: 843571. <https://pubmed.ncbi.nlm.nih.gov/843571/>

