


Processamento de Linguagem Natural

Profa. Helena Caseli
helenacaseli@ufscar.br

Tarefas e Técnicas de PLN
Desambiguação Lexical de Sentido,
Anotação de Papéis Semânticos e
Extração de Informação



Tarefas e técnicas de PLN

Contextualização

- PLN visa construir aplicações/sistemas capazes de processar a língua natural
- Dando continuidade às tarefas de PLN e as principais estratégias para executá-las
 - Hoje falaremos de três tarefas que relacionam significados
 - Desambiguação lexical de sentido (*word sense disambiguation*, WSD)
 - Anotação de papéis semânticos (*semantic role labeling*, SRL)
 - Extração de informação (*information extraction*, IE)

Tarefas e técnicas de PLN

Desambiguação lexical de sentido, Anotação de papéis semânticos e Extração de informação

- Todas as três tarefas focam no relacionamento de significado das palavras
 - WSD visa encontrar o significado da palavra em um determinado contexto
 - SRL está preocupada em atribuir o papel que as sequências de palavras desempenham na frase
 - IE foca nas relações conceituais entre elementos da sentença
- WSD e SRL são consideradas no nível da semântica lexical
- IE e SRL, também estão na fronteira da sintaxe com a semântica
 - Se beneficiam bastante da análise sintática vista na aula anterior
- Todas as três tarefas podem ser vistas como uma primeira tentativa de entendimento/interpretação da linguagem

Tarefas e técnicas de PLN

Desambiguação lexical de sentido

- Contextualização
- Recursos
- Estratégias
- Avaliação

Desambiguação lexical de sentido

O que é?

- Palavras são **ambíguas**, ou seja, a mesma palavra pode ter diferentes sentidos
 - Palavras que podem ter diferentes sentidos são chamadas de **polissêmicas**
- Sentido
 - **Representação discreta** de um aspecto do significado da palavra
- Quantos sentidos?
 - Em dicionários (recursos lexicais), cada sentido é uma entrada separada
 - Em *word embeddings* contextualizadas, cada ocorrência da palavra (o sentido naquela ocorrência) tem um vetor

Desambiguação lexical de sentido

O que é?

- Desambiguação lexical de sentido
 - É a tarefa de determinar qual **sentido** de uma palavra está sendo usado em um determinado **contexto**

O **banco** da praça está vazio.

Assento, lugar onde alguém pode se sentar

Vou ao **banco** sacar dinheiro.

Instituição financeira, local onde é possível fazer movimentações financeiras

Tarefas e técnicas de PLN

Desambiguação lexical de sentido

- Contextualização ✓
- **Recursos**
- Estratégias
- Avaliação

Desambiguação lexical de sentido

WordNet (FELLBAUM, 1998)

- Base de conhecimento léxico-semântica que organiza os itens lexicais (palavras ou expressões) em *synsets* (*synonym sets*, conjuntos de sinônimos)
 - Cada *synset* expressa um conceito em particular e é composto por
 - Glosa: explicação/definição do conceito
 - Opcionalmente exemplos de uso
 - Os *synsets* se relacionam por meio de relações

Desambiguação lexical de sentido

WordNet de Princeton

- Interface de visualização (descontinuada)
 - Imagens recuperadas do curso de PLN do ICMC (Prof. Thiago Pardo e Profa. Graça Nunes)

WordNet Search - 3.1

- [WordNet home page](#) - [Glossary](#) - [Help](#)

Word to search for:

Display Options:

Key: "S:" = Show Synset (semantic) relations, "W:" = Show Word (lexical) relations

Display options for sense: (gloss) "an example sentence"

Noun

- [S:](#) (n) **bass** (the lowest part of the musical range)
- [S:](#) (n) **bass**, [bass part](#) (the lowest part in polyphonic music)
- [S:](#) (n) **bass**, [basso](#) (an adult male singer with the lowest voice)
- [S:](#) (n) [sea bass](#), **bass** (the lean flesh of a saltwater fish of the family Serranidae)
- [S:](#) (n) [freshwater bass](#), **bass** (any of various North American freshwater fish with lean flesh (especially of the genus Micropterus))
- [S:](#) (n) **bass**, [bass voice](#), [basso](#) (the lowest adult male singing voice)
- [S:](#) (n) **bass** (the member with the lowest range of a family of musical instruments)
- [S:](#) (n) **bass** (nontechnical name for any of numerous edible marine and freshwater spiny-finned fishes)

Adjective

- [S:](#) (adj) **bass**, [deep](#) (having or denoting a low vocal or instrumental range) "a deep voice"; "a bass voice is lower than a baritone voice"; "a bass clarinet"

Desambiguação lexical de sentido

Relações entre sentidos

São a base conceitual para criação de recursos como Taxonomias (só hiperonímia) Ontologias (outras relações)

- As principais são
 - Sinonímia
 - Quando os sentidos de duas unidades lexicais diferentes são “idênticos” ou muito próximos
 - Ex.: carro e automóvel, morrer e bater as botas, belo e bonito
 - Antonímia
 - Quando os sentidos das unidades lexicais são opostos
 - Ex.: ir e voltar, bonito e feio, dentro e fora
 - Hiperonímia (Hiponímia)
 - Quando a relação entre os sentidos é de um ser a superclasse do outro
 - Ex.: “veículo” é hiperônimo de “carro” (“carro” é hipônimo de “veículo”)
 - Meronímia (Holonímia)
 - Quando a relação entre os sentidos é de um ser parte do outro
 - Ex.: “roda” é merônimo de “carro” (“carro” é holônimo de “roda”)

Desambiguação lexical de sentido

Recursos

- TeP e Wordnet.Br
 - <https://sites.google.com/view/nilc-usp/tep-2-0>
 - <https://sites.google.com/view/nilc-usp/wordnetbr1>
- OpenWordnet-PT
 - <https://github.com/own-pt/openWordnet-PT>
- Onto.PT e CONTO.PT
 - <http://ontopt.dei.uc.pt/>
 - <http://ontopt.dei.uc.pt/index.php?sec=contopt>
- PAPEL
 - <https://www.linguateca.pt/PAPEL/>
- PULO
 - <http://wordnet.pt/>

Desambiguação lexical de sentido

Recursos

- PULO – exemplo de consulta para a palavra polissêmica “banco”

Portuguese_3.0

Synset:

assento  

banco  

Gloss:

mobiliário que é projetado para sentar-se em

Portuguese_3.0

Synset:

banco  

Gloss:

uma instituição financeira que aceita depósitos e canais de o dinheiro em atividades de empréstimo

Dois dos vários
synsets associados à
“banco” no PULO

Desambiguação lexical de sentido

Recursos

- TeP 2.0 – exemplo de consulta de synsets relacionados a “carro”

base_tep2.txt

12821. [Substantivo] {auto, solenidade}
 12822. [Substantivo] {arquivo, auto, registro}
 12823. [Substantivo] {auto, automóvel, **carro**, veículo}
 12824. [Substantivo] {auto-admiração, autocontemplação, narcisismo}
 12825. [Substantivo] {autoctonia, autoctonismo}

base_tep2.txt

13179. [Substantivo] {meio, veículo}
 13180. [Substantivo] {**carroçaria**, **carroceria**}
 13181. [Substantivo] {**carro**-de-combate, tanque}
 13182. [Substantivo] {**carro**-guincho, guincho, reboque}
 13183. [Substantivo] {**carro**-leito, vagão-dormitório, vagão-leito}
 13184. [Substantivo] {caminhão-pipa, **carro**-pipa}

Desambiguação lexical de sentido

Recursos

- TeP 2.0 – exemplo de consulta de relações entre palavras

```
triplos.txt
7087 [Adjetivo] conglutinoso SINONIMO DE pegajento
7088 [Substantivo] gênero SINONIMO DE jaez
7089 [Substantivo] carro SINONIMO DE veículo
-----
80249 [Verbo] desligar-se SINONIMO DE estremar-se
80250 [Adjetivo] bulhão SINONIMO DE turbulento
80251 [Substantivo] honestidade SINONIMO DE pundonor
80252 [Adjetivo] bonito ANTONIMO DE feio
-----
116381 [Substantivo] obcecação ANTONIMO DE lucidez
116382 [Adjetivo] contínuo ANTONIMO DE descontinuado
116383 [Advérbio] dentro ANTONIMO DE fora
116384 [Verbo] marear SINONIMO DE vogar
```

Tarefas e técnicas de PLN

Desambiguação lexical de sentido

- Contextualização ✓
- Recursos ✓
- **Estratégias**
- Avaliação

Desambiguação lexical de sentido

Como é feita?

- Os algoritmos de WSD
 - Têm como entrada uma palavra em contexto e um conjunto fixo de possíveis sentidos para ela
 - Geram como saída o sentido correto naquele contexto

O banco da praça está vazio.

Assento, lugar onde
alguém pode se sentar

Vou ao banco sacar dinheiro.

Instituição financeira,
local onde é possível
fazer movimentações
financeiras

Desambiguação lexical de sentido

Como é feita?

- Baselines
 - Atribuir sempre o sentido mais frequente (p.ex. o primeiro na WordNet)
 - *Most frequent sense*
 - Considerar que, em um determinado texto, a palavra será sempre usada com o mesmo sentido
 - *One sense per discourse*
 - Algoritmo de Lesk
 - Com base na WordNet
 - Atribui o sentido cuja glosa/definição compartilha o maior número de palavras com o contexto da palavra alvo

Vou ao **banco** sacar dinheiro.

Assento, lugar onde
alguém pode se sentar

Instituição financeira,
local onde é possível
fazer movimentações
financeiras


Desambiguação lexical de sentido

Para saber mais:

Leia o [Apêndice G](#) de (JURAFSKY; MARTIN, 2025)

AM não supervisionado

- *Embeddings* contextualizadas + vizinhos mais próximos



AM supervisionado

- *Features* (considerando uma janela de palavras à esquerda e à direita)
 - PoS tags
 - n-gramas
 - *embeddings* ponderadas pela distância da palavra a ser rotulada
- + algoritmos de AM (p.ex. SVM)

Tarefas e técnicas de PLN

Desambiguação lexical de sentido

- Contextualização ✓
- Recursos ✓
- Estratégias ✓
- **Avaliação**

Desambiguação lexical de sentido

Avaliação

- Considera
 - Sentido correto
- Medidas
 - Precisão
 - Cobertura
 - F1
- Pode levar em consideração a dificuldade da desambiguação, ou seja, palavras com mais sentidos podem ser mais difíceis de desambiguar
- *Datasets* disponíveis como *benchmark*: Senseval e SemEval

Tarefas e técnicas de PLN

Anotação de papéis semânticos

- Contextualização
- Formalismos
- Estratégias
- Avaliação
- Recursos

Anotação de papéis semânticos

Contextualização

- Papel temático
 - Quem? O quê? Pra quem? Como? Quando? Onde?

A menina postou uma foto.

Pergunta	Resposta	Função sintática	Papel temático
Quem?	a menina	sujeito	Agente
Fez o quê?	postou uma foto	predicado	—
Postou o quê?	uma foto	objeto	Objeto Estativo

AGENTE
EXPERIENCIADOR
TEMA
INSTRUMENTO
BENEFICIÁRIO
OBJETIVO
ORIGEM
RESULTADO
CONTEÚDO

Anotação de papéis semânticos

Contextualização

- Os papéis temáticos podem se subdividir (p.ex. para verbos específicos) ou se agrupar em vários outros papéis (p.ex. PROTO-AGENT)
- Papéis semânticos
 - Dão uma representação rasa do significado (semântica)
 - Ajudam a fazer inferências que não são possíveis quando analisamos apenas as palavras (morfologia) ou a árvore sintática (sintaxe)
 - Generalizam sobre diferentes formas de realização superficial dos argumentos de um verbo

Anotação de papéis semânticos

Contextualização – Exemplos

João quebrou o copo.

AGENTE

TEMA

João quebrou o copo com um martelo.

AGENTE

TEMA

INSTRUMENTO

O martelo quebrou o copo.

INSTRUMENTO

TEMA

O copo quebrou.

TEMA

O copo foi quebrado pelo João.

TEMA

AGENTE

Thematic Role	Definition
AGENT	The volitional causer of an event
EXPERIENCER	The experiencer of an event
FORCE	The non-volitional causer of the event
THEME	The participant most directly affected by an event
RESULT	The end product of an event
CONTENT	The proposition or content of a propositional event
INSTRUMENT	An instrument used in an event
BENEFICIARY	The beneficiary of an event
SOURCE	The origin of the object of a transfer event
GOAL	The destination of an object of a transfer event

Tarefas e técnicas de PLN

Anotação de papéis semânticos

- Contextualização ✓
- **Formalismos**
- Estratégias
- Avaliação
- Recursos

Anotação de papéis semânticos

PropBank (Propositional Bank) (PALMER et al., 2005)

- Usa papéis genéricos (Arg0, Arg1, Arg2 etc.) específicos para cada verbo
- Em geral
 - Arg0: AGENTE
 - Arg1: PACIENTE
 - E a semântica dos demais argumentos é definida para cada verbo, tentando seguir algumas padronizações

Anotação de papéis semânticos

PropBank (Propositional Bank) (PALMER et al., 2005)

- Exemplo
 - verbo “increase” (aumentar) e seus argumentos no PropBank

(21.13) **increase.01** “go up incrementally”

Arg0: causer of increase

Arg1: thing increasing

Arg2: amount increased by, EXT, or MNR

Arg3: start point

Arg4: end point

Arg0

Arg1

Arg2

O Passarinho aumentou o preço da banana.

O preço da banana aumentou de novo no Passarinho.

O preço da banana aumentou 5%.

Anotação de papéis semânticos

FrameNet (BAKER et al., 1998)

- Usa papéis semânticos que são específicos para uma ideia geral chamada de *frame*
 - Baseada na semântica de *frames* (FILLMORE et al., 1976) e teoria de *frames* (MINSKY, 1975)
 - “É uma estrutura hierárquica conceitual que define uma situação, objeto ou evento por meio de seus participantes e relacionamentos” (SENO et al., 2026)
- Semântica de *frames*
 - É uma teoria que propõe que “o entendimento do sentido de um item lexical envolve mais do que conhecer sua definição no dicionário: é necessário também ativar um conjunto de conhecimentos socialmente compartilhados sobre o mundo e sobre as situações em que ele costuma ser usado. Esse conjunto é chamado, na teoria, de *frame*.” (GAMONAL et al., 2026)

Anotação de papéis semânticos

FrameNet (BAKER et al., 1998)

- Associa papéis semânticos não somente a verbos, mas também a substantivos, adjetivos, advérbios entre outros
- Possui relações semânticas entre *frames* (p.ex. herança, causalidade)
- Dizemos que um determinado item lexical, por exemplo o verbo “medicar”, **evoca** um *frame* do cenário da saúde (GAMONAL et al., 2026)

Anotação de papéis semânticos

FrameNet

- Exemplo

O preço da banana aumentou 5%.

Arg1

Arg2

O preço da banana subiu 5%.

Houve um aumento de 5% no preço da banana.

Frame

Remete à ideia de mudança de posição de um item em uma escala

Anotação de papéis semânticos

Para saber mais:

Leia o [Capítulo 17 \(Volume 3\)](#) do livro de PLN do BPLN

FrameNet Brasil

- Exemplo
 - Definição
 - Elementos de *frame*

Intervenção_em_saúde @Health #1155 Medical_intervention [en] PDF

Definition

As Intervenções baseadas em procedimentos ou em medicina são usadas no **Paciente** para tentar aliviar uma **Condição_médica**. Essas intervenções podem ter uma **Frequência_de_sucesso** e **Efeitos_colaterais**. Esse frame difere-se de Cura, já que este frame lida apenas com tentativas de aliviar uma **Condição_médica**, enquanto Cura lida com situações em que a aflição ou a **Condição_médica** foi curada.

Frame Elements

Core	
Condição_em_saúde	Uma descrição holística do estado médico do paciente (ou uma parte do estado do paciente), que pode ou não indicar a causa de um desvio do normal.
Intervenção	Um medicamento ou procedimento é administrado ou realizado para tratar uma Condição_médica .
Paciente	Indivíduos que recebem Intervenção por causa de alguma condição em saúde.
Profissional_em_saúde	O indivíduo ou equipe que tenta melhorar a condição médica do Paciente .
Resultado	A consequência da Intervenção .

Tarefas e técnicas de PLN

Anotação de papéis semânticos

- Contextualização ✓
- Formalismos ✓
- **Estratégias**
- Avaliação
- Recursos

Anotação de papéis semânticos

O que é?

- Anotação de papéis semânticos ou *Semantic Role Labeling* (SRL)
 - Atribuição de papéis semânticos às sequências de texto (argumentos e predicados) nas sentenças

Como é feita?

- AM supervisionado usando FrameNet ou PropBank para especificar
 - Predicados
 - Papéis semânticos
 - Exemplos de treinamento e teste

Anotação de papéis semânticos

Para saber mais:


Leia a [seção 21.6](#) de (JURAFSKY; MARTIN, 2025)

AM baseado em *features*

- A partir de uma sentença analisada sintaticamente
 - Poda – heurísticas podam a árvore para desconsiderar os constituintes que provavelmente não seriam argumentos
 - Identificação – classificação binária de cada nó como candidato (1) ou não (0) a argumento
 - Classificação – classificação 1-para-N (onde N é a quantidade de possíveis papéis semânticos) dos candidatos definidos no passo anterior

AM neural

- Rotulação sequencial usando a estratégia BIO



Tarefas e técnicas de PLN

Anotação de papéis semânticos

- Contextualização ✓
- Formalismos ✓
- Estratégias ✓
- **Avaliação**
- Recursos

Anotação de papéis semânticos

Avaliação

- Considera
 - Rótulo correto
 - Sequência de palavras (ou constituinte) correta
- Medidas
 - Precisão
 - Cobertura
 - F1
- A identificação (binária) e a classificação (multiclasse) podem ser avaliadas separadamente
- *Datasets* disponíveis como *benchmark*: CoNLL-2005 e CoNLL-2012

Tarefas e técnicas de PLN

Anotação de papéis semânticos

- Contextualização ✓
- Formalismos ✓
- Estratégias ✓
- Avaliação ✓
- **Recursos**

Anotação de papéis semânticos

Recursos para o português

- PropBank.Br
 - Versões
 - Alinhamento com PropBank do inglês
 - v1.0 anotações a partir de árvores sintáticas revisadas do *corpus* Bosque
 - v2.0 contém 8.350 instâncias anotadas com papéis semânticos para textos jornalísticos do *corpus* PLN-Br a partir de árvores sintáticas geradas pelo PALAVRAS (BICK, 2000) sem revisão humana
 - <https://nilc-nlp.github.io/portlex/pages/pt/projetos/propbankbr.html>

Anotação de papéis semânticos

Recursos

- FrameNets para o português
 - FrameNet Brasil (FN-Br)
 - <https://www2.ufjf.br/framenetbr/>

Cometer_crime

Definição

Um **Criminoso** (geralmente intencionalmente) comete um **Crime**, ou seja, faz algo que não é permitido pelas leis da sociedade.

Elementos de Frame Nucleares

FE Core:

Criminoso
semantic_type: @sentient O indivíduo que comete o **Crime**.

FE Core-Unexpressed:

Crime
 Um ato cometido, geralmente intencional, que é formalmente proibido por lei.

Elementos de Frame Não-Nucleares

Explicação

semantic_type: @state_of_affairs Um estado de coisas ao qual o **Criminoso** está respondendo em seu **Crime**.

Finalidade

semantic_type: @state_of_affairs A ação que o **Criminoso** estava tentando realizar no **Crime**.

Frequência

A frequência com a qual um **Crime** é cometido.

Tarefas e técnicas de PLN

Extração de informação

- Considerações iniciais

Extração de informação

O que é?

- Processo de transformar **informação não estruturada** presente nos textos em **informação estruturada**
- Extração de entidades nomeadas (REN)
 - Vista na aula 05
- **Extração de relações (ER)**
 - Processo de encontrar e classificar relações semânticas entre entidades mencionadas no texto
 - Ex: part-of(teclado,notebook)
- Entre outros (p.ex. extração de eventos)

Extração de informação

Para quê serve?

- Para popular uma base de dados ou um grafo de conhecimento úteis para diversas aplicações de PLN
 - Perguntas e respostas (*question answering*)
 - Sumarização automática
 - Recuperação de informação
 - etc.

Extração de informação

Evolução histórica

Regras

- Final de 1970 e década de 1980 – Abordagens baseadas em regras
 - Aplicação de regras para identificação de informações especificadas em *templates*
 - *Parsers* (analísadores sintáticos) + regras definidas manualmente
- Década de 1990 – Conferências MUC (*Message Understanding Conference*)
 - Sete conferências realizadas de 1987 a 1997
 - Inicialmente com foco em relatórios militares (era uma iniciativa da DARPA)
 - A partir de 1991 (MUC-3), foco em textos jornalísticos
 - Avaliação conjunta
 - Estruturaram a tarefa de ER e definiram medidas de avaliação
 - Surgimento das primeiras aplicações comerciais (p.ex. JASPER de 1992)

Extração de informação

Evolução histórica

- Década de 2000
 - Vários métodos de AM supervisionado ou semissupervisionado aplicados à ER
- Atualmente
 - Métodos neurais e aprendizado profundo
 - Proposição de arquiteturas neurais para ER
 - Geração de conjuntos de dados anotados (supervisão fraca)
 - Extração de informação aberta (*Open Information Extraction*, OIE ou OpenIE)
 - Extração de todas as relações possíveis expressas em um texto, sem a necessidade de pré-definir quais seriam as relações e as entidades

AM tradicional

AM profundo

Tarefas e técnicas de PLN

Extração de relações

- Contextualização
- Estratégias
- Avaliação
- Exemplos de projetos

Extração de relações

O que é?

- Identificação de **relacionamentos** existentes entre **entidades**
- As entidades e as relações são definidas considerando um determinado escopo (domínio)
 - Ex.: Domínio da geografia brasileira

Relação	Descrição	Exemplo
Pertence(Cidade, Unidade Federativa)	Sobre uma cidade que está localizada em uma determinada Unidade Federativa , dizemos que a primeira <i>pertence</i> a esta última.	Pertence(Salvador, Bahia)
Tem_Prefeito(Cidade, Pessoa)	Uma pessoa que executa a função administrativa de gestão do executivo em nível municipal de uma dada cidade é denominada de seu(sua) <i>prefeito(a)</i> .	Tem_Prefeito(Salvador, Bruno Reis)

Extração de relações

O que é?

- Entidade
 - Pode ser um objeto concreto (pessoa, livro, casa) ou até um conceito abstrato (cargo, sentimento, sintoma)
- Relação
 - Relacionamento que vincula duas (ou mais) entidades

Relação Específica	Exemplo de Sentença	Extração
location-of(algo/alguém, local)	Um aluno pode ser encontrado na escola	location-of(aluno, escola)
is-a(subclasse, superclasse)	Salvador é uma cidade	is-a(Salvador, cidade)
part-of(todo, parte)	Roda é um componente de um carro	part-of(roda, carro)

Extração de relações

O que é?

As aulas de geografia dos alunos que cursam o ensino médio na Escola Estadual Vicente Telles de Souza, zona Centro-Sul de Manaus, foram realizadas de uma forma dinâmica e inovadora.




As aulas de geografia dos alunos que cursam o ensino médio na Escola Estadual Vicente Telles de Souza_{e1}, zona Centro-Sul_{e2} de Manaus_{e3}, foram realizadas de uma forma dinâmica e inovadora.



location-of(e1,e2)
location-of(e2,e3)

Extração de relações

Exemplos de tipos de relações gerais



Relations	Types	Examples
Physical-Located	PER-GPE	He was in Tennessee
Part-Whole-Subsidiary	ORG-ORG	XYZ , the parent company of ABC
Person-Social-Family	PER-PER	Yoko 's husband John
Org-AFF-Founder	PER-ORG	Steve Jobs , co-founder of Apple ...

Tarefas e técnicas de PLN

Extração de relações

- Contextualização ✓
- **Estratégias**
- Avaliação
- Exemplos de projetos

Extração de relações

Como é feita?

Para saber mais:

Leia os trabalhos citados na [seção 3.4.3](#) de (CLARO et al., 2026)

- Há abordagens que
 - Realizam a extração conjunta de entidades (NER) e relações (ER) ou
 - Fazem a extração de forma sequencial:
 - Primeiro identificam as entidades
 - Depois, as relações entre elas
- “A literatura recente aponta para as vantagens da identificação conjunta ao permitir um melhor aprendizado de restrições para identificação de entidades e relações” (CLARO et al., 2026)
- Considerando a extração de relações a partir de entidades já identificadas, temos 4 estratégias mais usuais ...

Extração de relações

1. Baseada em padrões manuais

- Estratégia mais antiga e ainda utilizada
- Definem-se padrões léxico-sintáticos das relações que se deseja extrair

Exemplos de padrões de Hearst (1992) para a relação de hiponímia

Padrão	Exemplo	Extração
NP , tais quais $\{NP\}^*NP$	... países, tais quais França, Brasil e China	Is_a(França, país)
$NP\{, NP\}^*$ e outros(as) NP	Contusões, feridas, osso quebrados e outras lesões	Is_a(contusão, lesão)

Extração de relações

1. Baseada em padrões manuais

- Os padrões podem conter especificações (restrições) das entidades nomeadas envolvidas

PER, POSITION of ORG:

George Marshall, Secretary of State of the United States

PER (named|appointed|chose|etc.) PER Prep? POSITION

Truman appointed Marshall Secretary of State

PER [be]? (named|appointed|etc.) Prep? ORG POSITION

George Marshall was named US Secretary of State

👍 Alta precisão
👎 Baixa cobertura

Extração de relações

2. Por meio de AM supervisionado

- A partir de um conjunto fixo de entidades e relações, um *corpus* de treinamento é anotado à mão
- O *corpus* de treinamento é usado para treinar um classificador que será capaz de rotular novos textos
- Abordagem padrão
 - Encontrar os pares de entidades
 - Aplicar um classificador de relação em cada par
- Pode-se usar um classificador intermediário, binário, que apenas determina se pode haver algum tipo de relação entre as duas entidades

Extração de relações

2. Por meio de AM supervisionado

- A tarefa de ER se reduz a identificar quando uma sentença ou um fragmento textual denota uma relação semântica entre duas entidades

[Gripe aviária]_{e1} é uma doença infecciosa causada pelo vírus da [influenza tipo a]_{e2}

Causa-Efeito(e1,e2)

- Técnicas
 - AM baseado em *features* (*bag of words*, tipo das entidades, infos sintáticas)
 - AM profundo (*fine-tuning* de algum modelo pré-treinado)

👍 Alta precisão
👎 Baixa generalização
👎 Anotação manual

Extração de relações

3. Por meio de AM semissupervisionado

- Via *bootstrapping*
 - A partir de um conjunto de **padrões semente** (*seed patterns*)
 - E **grandes corpora**, busca-se recursivamente por **instâncias** que casem com os padrões
 - Para essas instâncias, os **contextos** são extraídos e generalizados se tornando novos padrões

Extração de relações

3. Por meio de AM semissupervisionado

- Exemplo ... A partir do fato de que Ryanair tem um hub em Charleroi
 - Considerando as sentenças

(20.6) Budget airline Ryanair, which uses Charleroi as a hub, scrapped all weekend flights out of the airport.

(20.7) All flights in and out of Ryanair's hub at Charleroi airport were grounded on Friday...

(20.8) A spokesman at Charleroi, a main hub for Ryanair, estimated that 8000 passengers had already been affected.

Extraímos os padrões:

```
/ [ORG], which uses [LOC] as a hub /
/ [ORG]'s hub at [LOC] /
/ [LOC], a main hub for [ORG] /
```

Esses novos padrões
podem ser usados
para buscar instâncias

Extração de relações

3. Por meio de AM semissupervisionado

- Problema: Desvio semântico (*semantic drift*)
 - Quando um padrão equivocado leva à identificação de instâncias erradas, que leva à criação de novos padrões errados e assim por diante
 - Ex:
(20.9) Sydney has a ferry hub at Circular Quay.
- Solução
 - Atribuir valores de confiança para os padrões baseados em:
 - hits(p): acertos de p em relação a uma coleção de documentos D
 - finds(p): casamentos (*pattern matching*) de p em D

$$Conf_{RlogF}(p) = \frac{|hits(p)|}{|finds(p)|} \log(|finds(p)|)$$

Geralmente normalizada para corresponder a probabilidades

Extração de relações

👍 Sem supervisão
👎 Baixa precisão

4. Por meio de supervisão distante (*distant supervision*)

- Combina as vantagens do *bootstrapping* e do aprendizado supervisionado
 - Ex: born-in(Pessoa, Cidade) com base na Wikipedia (DBPedia, Freebase)

100.000 exemplos

<Edwin Hubble, Marshfield>
<Albert Einstein, Ulm>

...

Instâncias

<born-in, Edwin Hubble, Marshfield>
<born-in, Albert Einstein, Ulm>
<born-year, Albert Einstein, 1879>

...

800.000 artigos

... Hubble was born in Marshfield ...
... Einstein, born (1879), Ulm ...
... Hubble's birthplace in Marshfield ...

...

Padrões

PER was born in LOC
PER, born (XXXX), LOC
PER's birthplace in LOC

Tarefas e técnicas de PLN

Extração de relações

- Contextualização ✓
- Estratégias ✓
- **Avaliação**
- Exemplos de projetos

Extração de relações

Avaliação

- Precisão (P)

$$P = \frac{\#(\text{relacionamentos corretamente extraídos})}{\#(\text{relacionamentos extraídos pelo sistema})}$$

- Revocação (R)

$$R = \frac{\#(\text{relacionamentos extraídos})}{\#(\text{relacionamentos no } corpus)}$$

- F1

$$F1 = \frac{2 * P * R}{P + R}$$

Extração de relações

Avaliação

- Labeled vs. Unlabeled
 - Labeled: para ser considerada correta, as entidades e o rótulo da relação têm que estar corretos
 - Unlabeled: para ser considerada correta, basta que exista de fato uma relação entre as entidades, independente do rótulo atribuído a ela
- Em abordagens semissupervisionadas (ou não supervisionadas)
 - Não há um *gold standard* (conjunto de referência) adequado
 - Calcula-se apenas a precisão em uma amostragem aleatória da saída gerada que é checada por humanos
 - Pode-se combinar a estratégia com a análise dos top-n candidatos ordenados de acordo com alguma medida de confiança

Tarefas e técnicas de PLN


Extração de relações

- Contextualização ✓
- Estratégias ✓
- Avaliação ✓
- **Exemplos de projetos**

Extração de relações

Exemplos de projetos

- Open Mind Common Sense
 - Projeto do MIT Media Lab
 - Visava construir uma base de conhecimento de senso comum baseado em
 - ConceptNet



Extração de relações

Exemplos de projetos

- Open Mind Common Sense
 - Na UFSCar, projeto Senso Comum coordenado pela Profa. Junia Anacleto (in memoriam)



A Portuguese term in ConceptNet 5.8

Sources: Open Mind Common Sense contributors, DBPedia 2015, Unicode CLDR, German Wiktionary, English Wiktionary, French Wiktionary, and Open Multilingual WordNet
View this term in the API

[Documentation](#)
[FAQ](#)
[Chat](#)
[Blog](#)

Location of banco

pt praça →
 pt ponto de ônibus →
 pt praça pública →
 pt carro →
 pt ponto de táxi →
 pt onibus →

Things located at banco

pt dinheiro →
 pt fila →
 pt caixa →
 pt gerente →
 pt caixa eletrônico →
 pt cheque →

banco is used for..

pt sentar →
 pt depositar dinheiro →
 pt guardar dinheiro →
 pt sacar dinheiro →
 pt crédito →
 pt depositar →

Synonyms

en bench (n, artifact) →
 en bank (n, artifact) →
 en depository financial institution (n, group) →
 de bank (n) →
 en bank (n) →

Fonte: <https://conceptnet.io/c/pt/banco> 65

Extração de relações

Exemplos de projetos

- Open Mind Common Sense – Senso Comum na UFSCar
 - [\(TABA; CASELI, 2014\)](#)
 - Extração de 7 relações semânticas baseadas no OMCS
 - *Corpora* anotados
 - CETENFolha – jornalístico
 - FAPESP – divulgação científica


Relation	CETENFolha	FAPESP
property-of	5114	853
is-a	2950	367
part-of	2105	306
location-of	1742	248
effect-of	169	84
used-for	138	68
made-of	82	60
none	112794	23985
Total	125094	25971

Fonte: (TABA; CASELI, 2014) 66

Extração de relações

Exemplos de projetos

- Open Mind Common Sense – Senso Comum na UFSCar
 - [\(TABA; CASELI, 2014\)](#)
 - Baseado em padrões de Hearst (1992)
 - Boa precisão
 - Baixa cobertura
 - AM baseado em *features*
 - Melhor algoritmo foi o SVM



Extração de relações

Exemplos de projetos

- Open Mind Common Sense – Senso Comum na UFSCar
 - [\(TABA; CASELI, 2014\)](#)
 - Exemplos de relações extraídas

Relation	Original context	Method
<i>is-a(Itália, país)</i> is-a(Italy, country)	<i>...ir para Itália ou qualquer outro país para...</i> ...go to Italy or any other country for...	is-a pattern #5
<i>property-of(mito, velho)</i> property-of(myth, old)	<i>...enterra em=parte o velho mito explicitado por...</i> ...buries in part the old myth explicitated by...	property-of pattern #1
<i>part-of(painéis, campanha)</i> part-of(panels, campaign)	<i>...que os painéis fizessem parte de a campanha de o...</i> ...that the panels made part of the campaign of the...	part-of pattern #2
<i>made-of(medalhas, ouro)</i> made-of(medals, gold)	<i>...Vegard=Ulvang , que ganhou três medalhas de ouro em o...</i> ...Vegard Ulvang, that won three gold medals in the...	made-of pattern #1
<i>effect-of(úlceras, morreu)</i> effect-of(ulcer, died)	<i>...Jandira morreu devido=a a úlcera perfurada .</i> ...Jandira died due to the perforated ulcer...	effect-of pattern #1

Extração de relações

Exemplos de projetos

- Open Mind Common Sense – Senso Comum na UFSCar
 - [\(TABA; CASELI, 2014\)](#)
 - Exemplos de relações extraídas

<i>part-of(USP, Equipe)</i> part-of(USP, Team)	<i>Equipe de a USP detalha os mecanismos...</i> Team from USP details the mechanisms...	Decision tree
<i>made-of(jatos, gases)</i> made-of(jets, gases)	<i>...evolução de jatos de gases com...</i> ...evolution of jets of gases with...	SVM
<i>effect-of(começou a chover e a ventar forte, desistir)</i> effect-of(started raining and gusting strongly, stop)	<i>...a volta começou a chover e a ventar forte , perto=de Ribeirão=Preto , e tivemos de desistir...</i> ...it started raining and gusting strongly, close to Ribeirão Preto, and we had to stop...	Decision tree
<i>used-for(terapia celular, tratar)</i> used-for(cellular therapy, treat)	<i>...usam terapia celular para tratar experimentalmente...</i> ...use cellular therapy to experimentally treat...	Decision tree
<i>location-of(sangue, corpo)</i> location-of(blood, body)	<i>...o sangue que corre por o corpo contém...</i> ...the blood that runs through the body contains...	SVM

Extração de relações

Exemplos de projetos

- [Read the Web](#)
 - Projeto da Carnegie Mellon University que contou com a participação do Prof. Estevam Hruschka quando era docente da UFSCar
 - NELL: Never-Ending Language Learning
 - Ler a web ininterruptamente para aprender conhecimento (entidades e relações)

actorsuchasactor

(relation: domain [actor](#), range [actor](#))

Describes the actor types that are generalizations of specific actors

See [metadata](#) for actorsuchasactor
16 instances, 1 page

instance	iteration	date learned	confidence
movie_actors, glenn_close	1103	18-mar-2018	(Seed) 100.0
movie_actors, robert_deniro	1048	13-apr-2017	(Seed) 100.0
movie_actors, sigourney_weaver	1116	12-sep-2018	(Seed) 100.0
movie_actors, marlon_brando	1080	02-dec-2017	(Seed) 100.0
movie_actors, meryl_streep	1115	03-sep-2018	(Seed) 100.0
movie_actors, dustin_hoffman	1115	03-sep-2018	(Seed) 100.0

Tarefas e técnicas de PLN – WSD, SRL e IE

Referências específicas desta aula

- Capítulos [20](#) e [21](#) e [Apêndice G](#) do livro de (JURAFSKY; MARTIN, 2025)
- Capítulos [9](#) do Volume 1, [3](#) e [17](#) do Volume 3 do livro de PLN do BPLN
- Curso de PLN dos Profs. Thiago Pardo e Graça Nunes do ICMC/USP

Links interessantes

- <https://github.com/sebastianruder/NLP-progress>

Tarefas e técnicas de PLN – WSD, SRL e IE

Leituras sugeridas

- [Capítulo 20](#) do livro de (JURAFSKY; MARTIN, 2025)
 - Com exceção da seção 20.2.5 (Open IE) e a partir da seção 20.3
- [Capítulo 21](#) do livro de (JURAFSKY; MARTIN, 2025)
 - Com exceção da seção 21.6
- [Apêndice G](#) do livro de (JURAFSKY; MARTIN, 2025)
- [Capítulo 9 do Volume 1](#) do livro de PLN do BPLN
 - Apenas as seções 9.1.1 e 9.1.2
- [Capítulo 17 do Volume 3](#) do livro de PLN do BPLN
 - Até a seção 17.3 (não precisa entrar nas subseções)
- [Capítulo 3 do Volume 3](#) do livro de PLN do BPLN
 - Com exceção da seção 3.5 e trechos sobre EN já abordados na aula 05