

Projeto de Processamento de Linguagem Natural

Detecção Automática de Fake News em Português Brasileiro

1. Tarefa Escolhida

A tarefa escolhida para este projeto é a detecção automática de fake news em português brasileiro. O objetivo consiste em desenvolver um sistema capaz de classificar notícias como falsas ou verdadeiras a partir da análise de seu conteúdo textual.

A disseminação de notícias falsas representa um problema significativo na sociedade contemporânea, especialmente em contextos relacionados à política, saúde pública e economia. Informações incorretas podem influenciar decisões individuais e coletivas, comprometer a confiança em instituições e gerar impactos sociais relevantes. Nesse contexto, técnicas de Processamento de Linguagem Natural (PLN) podem ser empregadas para automatizar a identificação desse tipo de conteúdo.

Do ponto de vista computacional, trata-se de uma tarefa de classificação de textos, na qual cada documento recebe uma das duas classes possíveis: fake (notícia falsa) ou true (notícia verdadeira). O sistema deverá analisar características linguísticas, estruturais e estatísticas do texto para realizar essa distinção.

Exemplo de classificação:

- "Vacina contra COVID-19 altera o DNA humano", classificada como fake.
- "Banco Central anuncia nova taxa básica de juros", classificada como true.

A escolha dessa tarefa se justifica por sua relevância social, pela disponibilidade de corpora em português brasileiro e pela ampla utilização do problema na literatura científica de PLN e aprendizado de máquina.

2. Dataset que Será Utilizado

O dataset selecionado para este projeto é o Fake.Br Corpus, desenvolvido por pesquisadores da Universidade de São Paulo e amplamente utilizado em estudos de detecção de fake news em português brasileiro.

[Repositório oficial do Fake.Br Corpus](#)

O corpus é composto por 7.200 notícias, sendo:

- 3.600 notícias falsas;
- 3.600 notícias verdadeiras.

Trata-se, portanto, de um conjunto de dados balanceado, o que favorece o treinamento e a avaliação de modelos de classificação.

Cada notícia contém informações como:

- título;
- texto completo;
- rótulo da classe (fake ou true);
- metadados adicionais.

Os textos pertencem a diferentes domínios, incluindo política, economia, saúde e cotidiano, proporcionando diversidade temática e maior robustez aos experimentos.

As principais características do dataset são:

- Idioma: português brasileiro;
 - Tipo de texto: notícias jornalísticas;
 - Número de classes: 2;
 - Tamanho total: 7.200 documentos;
 - Distribuição balanceada entre as classes.
-

3. Possíveis Estratégias a Serem Investigadas

Para atender aos requisitos do projeto, serão investigadas pelo menos duas estratégias distintas para resolver a tarefa de classificação.

Estratégia 1: Sistema Baseado em Regras

A primeira abordagem consistirá em um sistema baseado em regras heurísticas elaboradas a partir de características frequentemente associadas a notícias falsas.

Alguns exemplos de características que poderão ser exploradas incluem:

- uso excessivo de letras maiúsculas;
- grande quantidade de pontos de exclamação;
- presença de termos sensacionalistas;
- tamanho do texto;
- frequência de adjetivos e advérbios.

A decisão final poderá ser obtida a partir da combinação dessas características por meio de um sistema de pontuação.

Estratégia 2: Aprendizado de Máquina Supervisionado

A segunda abordagem utilizará algoritmos de aprendizado de máquina supervisionado.

Inicialmente, os textos serão pré-processados por meio de etapas como:

- tokenização;
- remoção de stopwords;
- lematização ou stemming;
- normalização textual.

Em seguida, os documentos serão convertidos em vetores numéricos utilizando a técnica TF-IDF (Term Frequency–Inverse Document Frequency), que representa cada texto com base na importância estatística de suas palavras.

Esses vetores serão utilizados como entrada para algoritmos como:

- Naive Bayes;
- Support Vector Machine;
- Random Forest;
- Logistic Regression.

Estratégia 3 (Opcional): Modelos Baseados em Transformers

Caso haja tempo disponível, pretende-se investigar também modelos de linguagem pré-treinados, como BERTimbau, especializado em português brasileiro.

Essa abordagem utiliza redes neurais profundas capazes de capturar relações semânticas complexas no texto e costuma apresentar desempenho superior em tarefas de classificação textual.

4. Modo de Avaliação da Tarefa

O desempenho das estratégias será avaliado por meio de métricas quantitativas amplamente utilizadas em tarefas de classificação de textos.

As principais métricas consideradas serão:

- Acurácia (Accuracy): proporção de classificações corretas;
- Precisão (Precision): proporção de previsões positivas que estão corretas;
- Revocação (Recall): proporção de exemplos positivos corretamente identificados;
- Medida F1 (F1-score): média harmônica entre precisão e recall.

A medida F1 é dada por:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Também será utilizada a matriz de confusão para analisar detalhadamente os tipos de erro cometidos pelos modelos.

Para garantir maior confiabilidade dos resultados, o dataset será dividido em conjuntos de treinamento e teste, podendo ainda ser empregada validação cruzada.

Além da avaliação quantitativa, será realizada uma avaliação qualitativa manual em uma amostra de notícias, permitindo identificar padrões de erro e compreender melhor o comportamento das abordagens investigadas.

Opcionalmente, poderá ser calculado o coeficiente de concordância entre os integrantes do grupo, como o Coeficiente Kappa de Cohen.

5. Considerações Finais

Este projeto propõe o desenvolvimento de um sistema para detecção automática de fake news em português brasileiro utilizando o Fake.Br Corpus. Serão comparadas abordagens baseadas em regras heurísticas e em aprendizado de máquina supervisionado, com possibilidade de extensão para modelos baseados em transformers.

A tarefa apresenta elevada relevância social e acadêmica, utiliza um corpus consolidado na literatura e permite explorar diversas técnicas fundamentais de Processamento de Linguagem Natural, desde o pré-processamento textual até a avaliação quantitativa e qualitativa de modelos.