


Processamento de Linguagem Natural

Profa. Helena Caseli
helenacaseli@ufscar.br

Tópicos avançados em PLN
Tradução automática



Tópicos avançados em PLN

Contextualização

- PLN visa construir aplicações/sistemas capazes de processar a língua natural
- Já vimos diversas tarefas de PLN úteis para diversas aplicações de PLN
- A partir desta aula veremos aplicações de PLN e as principais estratégias para implementá-las
 - Essas aplicações implementam/utilizam muitas das tarefas/ferramentas vistas nas aulas anteriores
 - Assim ...

Tópicos avançados em PLN


Tradução automática

- Contextualização
- Diversidade linguística
- Estratégias
- Avaliação
- Recursos
- Plus
- Exemplo de código
- Considerações finais

Tradução automática

O que é?

- Aplicação de PLN por meio da qual os computadores são usados para traduzir de uma língua natural (idioma) para outra
 - Em inglês, *Machine Translation* (MT)



- É considerada uma aplicação completa pois envolve a interpretação (NLU) da língua-fonte e a geração (NLG) da língua-alvo
- Há, ainda, a premissa fundamental de gerar uma saída que seja semanticamente equivalente à entrada

Tradução automática

Para quem serve?

Acesso à informação

Tradução Assistida por Computador (CAT¹)

Apoio à comunicação humana

- Originalmente a tradução era de texto para texto hoje ...



Imagem gerada pelo Nano Banana 2

Google Tradutor

Texto Imagens Documentos Sites

Detectar idioma Português (Brasil) Inglês ↔ Inglês Português (Brasil) Espanhol

Mostrar original ☒

Copiar texto Baixar tradução

Los dichos populares

"Boquerón que se duerme, se lo lleva la corriente."

Provérbios populares

"Uma anchova adormecida é levada pela correnteza."



Fonte:

<https://blog.google/products/workspace/google-workspace-gemini-may-2025-updates/>

Tradução automática

Quão difícil é realizar a tarefa?

The book is on the table.

X

Boquerón que se duerme,
se lo lleva la corriente.

Exemplo da aula 01

(pt) Estou preocupado com você.

(en) I'm worried about you.

(es) Me preocupa.

- Complexidade/diferenças das/entre as línguas envolvidas
- Subjetividade
- Adequação ao contexto/cultura
- Diversas possibilidades de tradução

Tópicos avançados em PLN

Tradução automática

- Contextualização ✓
- **Diversidade linguística**
- Estratégias
- Avaliação
- Recursos
- Plus
- Exemplo de código
- Considerações finais

Tradução automática

Características linguísticas (Tipologia linguística)

- Há cerca de 7.000 idiomas no mundo
- Alguns aspectos são comuns em (quase) todas as línguas humanas
 - Compartilhamento de conceitos e seus equivalentes lexicais
 - Ex.: Existem palavras para referenciar pessoas, falar sobre ações comuns como “comer” e “beber”, indicar uma forma de tratamento mais ou menos educada
 - Compartilhamento de estruturas
 - Ex.: Presença de substantivos (para denotar coisas) e verbos (para denotar ações), marcadores linguísticos para perguntas e ordens (ex. imperativo), concordância e discordância
- Contudo ...

Tradução automática

Entender as diferenças
pode levar a modelos de
TA melhores

Características linguísticas (Tipologia linguística)

- Há muitas **diferenças** na

- **Ordem das palavras**

- Línguas **SVO** (Sujeito-Verbo-Objeto) como o português, o inglês e o espanhol
- Línguas **SOV** (Sujeito-Objeto-Verbo) como o hindi e o japonês
- Línguas **VSO** (Verbo-Sujeito-Objeto) como o árabe

English: *He wrote a letter to a friend*

Japanese: *tomodachi ni tegami-o kaita*
friend to letter wrote

Arabic: *katabt risāla li šadq*
wrote letter to friend

Tradução automática

Entender as diferenças
pode levar a modelos de
TA melhores

Características linguísticas (Tipologia linguística)

- Há muitas **diferenças** no

- **Vocabulário**

- A escolha lexical mais adequada depende do **contexto**
- Por isso, WSD e TA estão bastante alinhadas

Fui ao **banco** sacar dinheiro.

I went to the **bank** to withdraw money.

Fui sentar no **banco** da praça.

I went to sit on a park **bench**.

- As palavras podem divergir em termos de **atributos morfológicos** (ex: gênero e número)

The student went to school by bus.

O aluno foi para a escola de ônibus.

Tradução automática

Entender as diferenças
pode levar a modelos de
TA melhores

Características linguísticas (Tipologia linguística)

- Há muitas **diferenças** no
 - **Vocabulário**
 - Itens lexicais para representar um conceito podem **não existir** em outro idioma (*lexical gap*)
 - Ex.: Dizem que “saudade” é uma palavra que só “existe” em português porque os possíveis equivalentes lexicais em outras línguas não expressam exatamente o mesmo conceito
 - As **propriedades conceituais** podem ser mapeadas de modo diferente

English: *The bottle floated out.*

Spanish: La botella salió flotando.

The bottle exited floating.

Fonte: (JURAFSKY; MARTIN, 2025 – Capítulo 13)

A propriedade que denota a direção está
na partícula

A propriedade que denota a direção está
no verbo

Tradução automática

Entender as diferenças
pode levar a modelos de
TA melhores

Características linguísticas (Tipologia linguística)

- Há muitas **diferenças** na
 - **Riqueza morfológica**
 - A tradução envolvendo línguas ricas morfológicamente (como o português) requer lidar com estruturas abaixo do nível da palavra, os **morfemas** (veja aula 02)
 - Por isso, modelos atuais lidam com **subpalavras**
 - **Densidade referencial**
 - A tradução também envolve decidir o que **omitir/explicitar**

Ontem **eu** fui para casa de ônibus.
Cheguei tarde e por isso não te liguei.

Yesterday **I** went home by bus. **I** arrived
late, so **I** didn't call you.

Tópicos avançados em PLN


Tradução automática

- Contextualização ✓
- Diversidade linguística ✓
- **Estratégias**
- Avaliação
- Recursos
- Plus
- Exemplo de código
- Considerações finais

Tradução automática

Estratégias


A BRIEF HISTORY OF MACHINE TRANSLATION



Tradução automática

Estratégias

- Triângulo de Vauquois (1968)



Paradigma linguístico (até 1980)

- Tradução direta
- Tradução baseada em regras
- Tradução por interlíngua

Paradigma empírico

- Tradução baseada em exemplos
- Tradução estatística
- Tradução neural

Tradução automática

Estratégias

- **Tradução direta**

- Mapeamento direto de palavras-fonte para palavras-alvo sem passar por outros níveis de análise
- Usa um **léxico bilíngue** e **casamento de padrões**

A casa do meu avô é linda.

_ house _ my granddad _ beautiful.

Limitações

Não realiza ordenamentos necessários na tradução entre línguas de sintaxe distinta

avô	granddad
avô	grandpa
avô	grandfather
casa	house
casa	home
linda	beautiful
meu	my
meu	mine

Tradução automática

Estratégias

- **Tradução automática baseada em regras**

- É um tipo de tradução por transferência que usa regras e léxico bilíngue
- A tradução é feita com base na análise da língua-fonte, seguida do mapeamento por meio de regras para a geração da saída na língua-alvo
- No inglês, *Rule-Based Machine Translation* (RBMT)

A casa do meu avô é linda.

<SUB> <PREP/de>+<DET/[a | o]> => 's <SUB>

The house of my grandfather is beautiful.

My grandfather's house is beautiful.

Tradução automática

Estratégias

- **Tradução automática baseada em regras**
 - Desvantagens
 - Necessidade de mapear o conhecimento linguístico em regras corretas, genéricas e abrangentes o suficiente para que sejam aplicáveis a vários exemplos
 - Demanda conhecimento das duas línguas (fonte e alvo) e das peculiaridades do mapeamento entre elas (ex. diferenças sintáticas)
 - É trabalhosa e custosa (um tradutor para outro par de línguas precisa ser criado do zero)
 - Baixa fluência das saídas

Tradução automática

Estratégias


- **Tradução automática baseada em regras**
 - Vantagens
 - Não demanda textos paralelos e, por isso, é uma boa opção para tradução de idiomas com recursos limitados
 - Seus recursos podem ser facilmente expandidos/atualizados
 - Traz maior controle e explicabilidade da saída gerada
 - Os primeiros sistemas comerciais de TA (década de 1970) eram baseados em regras

Tradução automática

Estratégias

- **Tradução automática por interlíngua**

- Utiliza uma **língua intermediária** (metalíngua), artificial, não ambígua e, portanto, mais simples de processar do que qualquer linguagem natural
- A tradução de uma língua-fonte para uma língua-alvo envolve
 - A tradução da língua-fonte para a língua intermediária (codificador)
 - A tradução da língua intermediária para a língua-alvo (decodificador)
- Problemas
 - Ingenuidade de acreditar que seria possível criar uma única linguagem capaz de representar todas as demais
 - Adoção unânime de uma língua pelos grupos de línguas distintas



Tradução automática

Estratégias

- **Paradigma empírico**

- Surgiu na tentativa de superar as limitações das estratégias do paradigma linguístico
 - Principalmente a dependência de especialistas humanos e o alto custo na geração de tradutores automáticos
- Envolve **estratégias baseadas em *corpus*** que só puderam funcionar graças a:
 - Avanços no hardware que permitiram processamentos computacionais mais pesados
 - Disponibilidade maior de recursos bilíngues, em especial *corpora* paralelos

Tradução automática

Estratégias

A ideia é aprender automaticamente a partir de exemplos de tradução

- **Paradigma empírico**

- Exemplo de *corpus* paralelo (Corpus FAPESP – Exemplo da aula 01)

The State of Parana creates a transgenic orange

Paraná cria laranja transgênica

Um pequeno grupo de pesquisadores do Instituto Agrônomo do Paraná (Iapar), em Londrina, conseguiu desenvolver uma variedade comercial de laranja com gene resistente a bactérias. O trabalho levou dois anos e teve baixo custo (entre R\$ 8 mil e R\$ 10 mil) porque foi feito um acordo com o Instituto Nacional de Recursos Agrobiológicos de Tsukuba, no Japão: os japoneses cederam o gene stx 1A, que codifica um peptídeo (fragmento de proteína) antibacteriano com alta atividade inibitória contra alguns tipos de bactérias.

Reorganized mammals

Mamíferos reorganizados

Pode estar próxima, enfim, a conciliação entre duas abordagens distintas de classificação zoológica - uma com base em dados morfológicos (de estudos anatômicos e fósseis) e outra em evidências moleculares (resultantes de análises de DNA). Biólogos da Universidade da Flórida, nos Estados Unidos, integraram 430 árvores filogenéticas com 315 artigos científicos publicados entre 1969 e 1999.

Como resultado, criaram mais seis ordens de um grupo de mamíferos - os que têm

Much more than worm tablets

Muito além dos vermífugos

Agora se sabe por que as cólicas, dores abdominais, vômitos, diarreias, fraqueza e palidez apareciam com frequência entre os estudantes do Ciep Juscelino Kubitschek, no Rio de Janeiro. Eram sinais de verminoses. Uma equipe da Escola Nacional de Saúde Pública (ENSP) da Fundação Oswaldo Cruz (Fiocruz) constatou que 45% dos 800 estudantes - de 4 e 17 anos de idade, acompanhados desde 1997 - carregavam os vermes que causavam ascaridíase, estrogiloidíase, ancilostomíase (amarelão) ou tricuriase.

Tradução automática

Estratégias

- **Paradigma empírico**

- Exemplo de *corpus* paralelo (*Corpus* FAPESP – Exemplo da aula 01)
 - **Alinhado sentencialmente** (por exemplo, por meio de análise de similaridade de cosseno calculada com base em um espaço vetorial multilíngue)

Paraná cria laranja transgênica

The State of Parana creates a
transgenic orange

Mamíferos reorganizados

Reorganized mammals

Muito além dos vermífugos

Much more than worm tablets

Tradução automática

Estratégias

- **Tradução automática baseada em exemplos**

- A tradução é realizada com base em **exemplos** previamente armazenados
 - Mais especificamente, em **trechos de texto**
- No inglês, *Example-Based Machine Translation* (EBMT)

A casa é muito bonita.

The house is very beautiful.

Meu avô foi internado ontem.

My grandfather was hospitalized yesterday.

Eu comprei uma jaqueta linda.

I bought a beautiful jacket.

A casa do meu avô é linda.

a casa

the house

meu avô

my grandfather

linda


beautiful

The house _ my grandfather _ beautiful.

Tradução automática

Estratégias

- TA é uma tarefa de **aprendizado de máquina supervisionado**
 - Treinamento: *corpus* paralelo
 - Meta: maximizar a probabilidade da sequência de *tokens* alvo dada uma sequência de *tokens* fonte
 - As sequências de entrada e saída não precisam ter o mesmo tamanho
 - Tarefa: sequence-to-sequence ou seq2seq



Tradução automática

Estratégias

- **Tradução automática estatística**

- A tradução é realizada com base em *corpus* paralelo e **estatística** (as probabilidades determinam a melhor tradução)
- Em inglês, *Statistical Machine Translation* (SMT)
 - *Word-based* SMT – a unidade de tradução é a palavra
 - **Phrase-based SMT (PBSM)** – a unidade de tradução é a sequência de palavras (*phrase*, n-grama)
 - *Syntax-based* SMT – a unidade de tradução são trechos de árvores sintáticas
- A tradução é realizada por meio de dois modelos computacionais
 - **Modelo de tradução** – especifica como mapear texto-fonte em texto-alvo
 - **Modelo de língua** – especifica como gerar um texto-alvo fluente

Tradução automática

Estratégias

- Tradução automática estatística

Modelo de tradução

Visa maximizar a
acurácia da
tradução

Probabilidades de tradução são
calculadas com base na
co-ocorrência no *corpus* paralelo

Modelo de língua

Visa maximizar a
fluência da
sentença gerada na
língua-alvo

Probabilidades de geração são
calculadas com base na ocorrência
no *corpus* monolíngue alvo

Tradução automática

Estratégias

- **Tradução automática estatística**
 - Modelo de tradução

A casa do meu avô é linda.

The house from my grandfather is beautiful.

The home of my grandfather é beautiful.

...

Id	frase-fonte (português)	frase-alvo (inglês)	probabilidade
1	a casa do	' house	0.0207779
2	a casa do	the house from	0.0623338
3	a casa	the house	0.297619
4	a casa	the home	0.0646474
5	do meu	of my	0.0813954
6	do meu	that of my	0.191576
7	meu avô	my grandfather	0.662453
8	meu avô , meu pai , eu	my grandfather , my father , me	0.0623338
9	avô	grandfather	0.916667
10	é	is	0.611613
11	é	é	0.794943
12	linda	beautiful	0.0389678
13	linda	pretty	0.00259724

Tradução automática

Estratégias

- **Tradução automática estatística**
 - Vantagens
 - As traduções estatísticas ganharam fluência em relação às estratégias anteriores
 - Uso mais eficiente de recursos humanos e dados
 - Desvantagens
 - Custo de criação de *corpora* paralelos
 - Dificuldade com pares de idiomas com ordem de palavras diferentes
 - O Google Tradutor, lançado em 2006/2007, era um tradutor PBSMT até se tornar neural a partir de 2016/2017

Tradução automática

Estratégias


- **Tradução automática neural**

- Em inglês, *Neural Machine Translation* (NMT)
- Ideia antiga (década de 1990, com alguns artigos sugerindo como redes neurais poderiam ser usadas para TA), mas que só foi possível a partir da maior disponibilização de dados em várias línguas e poder computacional
- A tradução é feita por meio de **redes neurais** *end-to-end* que mapeiam textos paralelos alinhados e são treinadas para maximizar a probabilidade de uma sequência-alvo dada uma sequência-fonte de entrada
 - Toda a sentença-fonte é considerada no aprendizado, de uma vez, e nos dois sentidos
 - Não há quebra em *phrases* nem divisão clara entre modelo de tradução e de língua

Tradução automática

Estratégias


- Tradução automática neural



Tradução automática

Estratégias


- **Tradução automática neural**
 - Usa *embeddings* para representar palavras
 - Ex.: *word embeddings* português e inglês do MUSE



Tradução automática

Estratégias

- Arquitetura encoder-decoder
 - É a arquitetura padrão para modelar tarefas sequence-to-sequence (seq2seq)



Tradução automática

Estratégias

- Arquitetura encoder-decoder
 - Encoder
 - Pega os *tokens* de entrada (x_i) e produz um contexto intermediário (h)
 - Decoder
 - Pega o contexto intermediário (h) e gera a saída *token a token* (y_i)

$$P(y_1, \dots, y_m | x_1, \dots, x_n)$$

subpalavras


$$\mathbf{h} = \text{encoder}(x)$$

$$y_{t+1} = \text{decoder}(\mathbf{h}, y_1, \dots, y_t) \quad \forall t \in [1, \dots, m]$$

Tradução automática

Estratégias


- Arquitetura encoder-decoder



Tradução automática

Estratégias

- Arquitetura encoder-decoder
 - Camada de atenção cruzada (*cross-attention*)
 - Permite que o decoder considere as projeções das palavras fonte produzidas pelo encoder




Tradução automática

Estratégias

- Arquitetura encoder-decoder
 - Visualização do modelo de atenção
 - Quanto mais claro, maior o “peso” da associação

A casa do meu avô é linda.


My grandfather's home is beautiful.



Tradução automática

Estratégias

- Arquitetura encoder-decoder
 - Algoritmo Beam Search (é o mais usado na decodificação)
 - Armazena as saídas mais prováveis
 - https://lena-voita.github.io/resources/lectures/seq2seq/general/beam_search.mp4



Tradução automática

Estratégias

- **Tradução automática neural**

- Limitações
 - Não é possível entender diretamente os motivos (parâmetros) que levaram à geração de uma determinada saída
 - Desempenho ruim em condições fora do domínio e para idiomas com recursos limitados
 - Demandam *corpus* maior e de melhor qualidade
- Vantagens
 - Apresentam uma fluência muito superior àquela das estratégias predecessoras

Tópicos avançados em PLN

Tradução automática

- Contextualização ✓
- Diversidade linguística ✓
- Estratégias ✓
- **Avaliação**
- Recursos
- Plus
- Exemplo de código
- Considerações finais

Tradução automática

Avaliação

- As traduções são avaliadas considerando duas **dimensões**
 - **Adequação**
 - Mede quão bem uma tradução captura o significado exato da sentença fonte
 - Também conhecida como *faithfulness* ou fidelidade
 - **Fluência**
 - Mede quão fluente é a tradução na língua alvo
 - Gramatical, clara, legível e natural

Tradução automática

Avaliação

- As traduções são avaliadas considerando duas **estratégias**
 - **Avaliação humana**
 - Atribuindo notas em uma escala de 1 a 5 (ou 100) para cada uma das sentenças de saída segundo as dimensões avaliadas
 - Ex.: notas para legibilidade, clareza, naturalidade etc. ou quão bem a sentença-alvo preserva a informação da sentença-fonte ou de uma sentença de referência
 - Ranqueando as saídas dos sistemas em avaliação
 - Pós-editando a saída do sistema em avaliação
 - É a mais indicada, porém muito custosa

Tradução automática

Avaliação

- As traduções são avaliadas considerando duas **estratégias**
 - **Avaliação automática**
 - Usada como uma estratégia intermediária
 - As medidas automáticas
 - São menos precisas do que a avaliação humana, mas podem ser úteis durante o desenvolvimento do sistema como um meio de comparação entre sistemas ou entre versões de um mesmo sistema
 - Podem ser usadas como uma função de perda durante o treinamento
 - Medidas baseadas em n-gramas
 - Medidas baseadas em similaridade

Tradução automática

Avaliação automática

- Medidas baseadas em n-gramas
 - Calculam a sobreposição de n-gramas entre uma sentença de referência (referência) e uma sentença traduzida automaticamente (candidata)
 - Ex. chrF, BLEU, METEOR, TER etc.
 - São mais apropriadas para comparar versões de um mesmo sistema do que sistemas entre eles

Tradução automática

Avaliação automática

- Medidas baseadas em n-gramas
 - chrF (character F-score)
 - Os n-gramas são de caracteres (com n máximo sendo k, geralmente k = 6)
 - chrP
 - Porcentagem da média de caracteres 1-grama, 2-gramas ... k-gramas na candidata que também ocorrem na referência
 - chrR
 - Porcentagem da média de caracteres 1-grama, 2-gramas ... k-gramas na referência que também ocorrem na candidata

$$\text{chrF}\beta = (1 + \beta^2) \frac{\text{chrP} \cdot \text{chrR}}{\beta^2 \cdot \text{chrP} + \text{chrR}} \quad \text{chrF2} = \frac{5 \cdot \text{chrP} \cdot \text{chrR}}{4 \cdot \text{chrP} + \text{chrR}}$$

Tradução automática

Avaliação automática

- Medidas baseadas em n-gramas
 - chrF
 - Exemplo de cálculo com $k = \beta = 2$

REF: witness for the past,

HYP1: witness of the past, chrF2,2 = .86

HYP2: past witness chrF2,2 = .62

REF: witnessforthevast, (18 unigrams, 17 bigrams)

HYP1: witnessofthevast, (17 unigrams, 16 bigrams)

unigrams that match: w i t n e s s f o t h e p a s t , (17 unigrams)

bigrams that match: w i i t n n e e s s t h h e e p p a a s s t t , (13 bigrams)

unigram P: $17/17 = 1$ unigram R: $17/18 = .944$

bigram P: $13/16 = .813$ bigram R: $13/17 = .765$

chrP = $(17/17 + 13/16)/2 = .906$

chrR = $(17/18 + 13/17)/2 = .855$

$$\text{chrF2,2} = 5 \frac{\text{chrP} * \text{chrR}}{4\text{chrP} + \text{chrR}} = .86$$

Tradução automática


Avaliação automática

- Medidas baseadas em n-gramas
 - BLEU (**B**iLingual **E**valuation **U**nderstudy)
 - Baseada apenas na precisão, e não na combinação de precisão e cobertura
 - Calcula a precisão de **n-gramas de palavras**
 - Porcentagem de 1-gramas, 2-gramas, 3-gramas e 4-gramas da candidata que também ocorrem na referência
 - Considera também uma penalidade de brevidade para penalizar candidatas que são muito pequenas
 - É muito sensível à tokenização, o que torna infactível comparar sistemas que usam estratégias de tokenização diferentes

Tradução automática

Avaliação automática

- Medidas baseadas em similaridade
 - Uma boa tradução pode usar palavras alternativas e paráfrases que preservam o significado da sentença fonte, mas são muito diferentes da referência
 - Ex.: METEOR (considera sinônimos), BERTScore (baseada em *embeddings*)



Tópicos avançados em PLN

Tradução automática

- Contextualização ✓
- Diversidade linguística ✓
- Estratégias ✓
- Avaliação ✓
- **Recursos**
- Plus
- Exemplo de código
- Considerações finais

Tradução automática

Recursos

- *Corpora* paralelos
 - Europarl
 - Textos do Parlamento Europeu nas 21 línguas da Europa
 - Entre 400.000 e 2 milhões de sentenças
 - <https://catalogue.elra.info/en-us/repository/browse/ELRA-W0090/>
 - *Corpus* FAPESP
 - Textos de divulgação científica da revista Pesquisa FAPESP
 - <http://www.nilc.icmc.usp.br/nilc/tools/Fapesp%20Corpora.htm>
 - OpenSubtitles
 - Legendas
 - <https://opus.nlpl.eu/OpenSubtitles/corpus/version/OpenSubtitles>

Tópicos avançados em PLN

Tradução automática


- Contextualização ✓
- Diversidade linguística ✓
- Estratégias ✓
- Avaliação ✓
- Recursos ✓
- **Plus**
- Exemplo de código
- Considerações finais

Tradução automática


Estratégias auxiliares

- Em situações de poucos recursos
 - **Aumento de dados** (*data augmentation*)

- *Backtranslation*



- A partir de um *corpus* paralelo pequeno, geramos uma primeira versão do sistema de TA que é usada para traduzir um *corpus* monolíngue bem maior
- O novo *corpus* paralelo sintético (■ + ■) pode, então, ser usado para gerar uma nova versão do sistema de TA



Tradução automática

Estratégias auxiliares

- Em situações de poucos recursos
 - **Modelos multilíngues**
 - O sistema de TA é treinado com sentenças paralelas em diversos pares de idiomas
 - Nesse caso, precisamos dizer ao sistema qual é o idioma fonte e qual é o idioma alvo na hora de traduzir
 - Vantagens
 - Podem melhorar o desempenho para idiomas com menos recursos com o aproveitamento do “conhecimento” de um idioma similar (durante o treinamento)

Tópicos avançados em PLN

Tradução automática

- Contextualização ✓
- Diversidade linguística ✓
- Estratégias ✓
- Avaliação ✓
- Recursos ✓
- Plus ✓
- **Exemplo de código**
- Considerações finais

Tradução automática

Exemplo de código

- Ajustando um modelo pré-treinado (T5) para a tradução en-pt

```
!pip3 install sentencepiece  
!pip3 install transformers  
!pip3 install translate-toolkit # Com funcionalidades para manipular textos paralelos
```

- Vamos usar o corpus do TED Talks Open Translation Project, com aproximadamente 50000 exemplos de treinamento, 1100 de validação e 2000 de teste

```
!wget https://object.pouta.csc.fi/OPUS-TED2020/v1/tmx/en-pt_br.tmx.gz  
!gunzip en-pt_br.tmx.gz
```

Tradução automática

Exemplo de código

- Ajustando um modelo pré-treinado (T5) para a tradução en-pt

```
from translate.storage.tmx import tmxfile
from random import shuffle

# ler córpus
with open("en-pt_br.tmx", 'rb') as fin:
    f = tmxfile(fin, 'en', 'pt')

prefixo = '>>pt_br<<'
# formatar as traduções corretamente
data = [{ 'src': prefixo + ' ' + w.source, 'trg': w.target } for w in f.unit_iter()]
# embaralhar os pares
shuffle(data)
# separar em conjuntos de treino e teste
size = int(len(data) * 0.2)
trainset = data[size:][:10000]
testset = data[:size][:1000]
```

O T5 é um modelo treinado para várias tarefas e idiomas, por isso é preciso especificar o idioma (nesse caso o idioma alvo)

Tradução automática

Exemplo de código

- Ajustando um modelo pré-treinado (T5) para a tradução en-pt

```
trainset[1]
```

```
{'src': '>>pt_br<< So in theory, yes, in theory, you can rise against a  
corporation, just as, in theory, you can rise against a dictatorship. ',  
 'trg': 'Em teoria, sim, você pode se rebelar contra uma corporação, assim como,  
em teoria, você pode se rebelar contra uma ditadura. '}
```

```
nepochs = 1  
batch_size = 16  
batch_status = 32  
learning_rate = 1e-5 # usar uma bem baixa para o caso dos modelos pré-treinados  
early_stop = 5  
write_path = 'model.pt' # caminho para salvar o melhor modelo
```

Tradução automática

Exemplo de código

- Ajustando um modelo pré-treinado (T5) para a tradução en-pt

```
from torch.utils.data import DataLoader, Dataset

traindata = DataLoader(trainset, batch_size=batch_size, shuffle=True)
devdata = DataLoader(testset, batch_size=batch_size, shuffle=True)
```

```
import nltk
nltk.download('punkt_tab')
import torch
from torch import optim
from transformers import AutoTokenizer, AutoModelForSeq2SeqLM

device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
model = AutoModelForSeq2SeqLM.from_pretrained("Helsinki-NLP/opus-mt-en-ROMANCE").to(device) # esse eh o modelo pre-treinado que vamos usar
tokenizer = AutoTokenizer.from_pretrained("Helsinki-NLP/opus-mt-en-ROMANCE") # o pt_br inserido anteriormente indica qual eh a lingua alvo
```

Tradução automática

Exemplo de código

- Ajustando um modelo pré-treinado (T5) para a tradução en-pt

```
# sentenças a serem traduzidas
batch_input_str = ((">>pt_br<< We can do better, America can do better, and help is on the way."),
                  (">>pt_br<< The boy went to school by bus."),
                  (">>pt_br<< My grandfather's house is beautiful.))

# tokenizando as sentenças
encoded = tokenizer(batch_input_str, return_tensors='pt', padding=True).to(device)

# traduzindo
translated = model.generate(**encoded)

# preparando a saída
tokenizer.batch_decode(translated, skip_special_tokens=True)
```

```
['Podemos fazer melhor, os Estados Unidos podem fazer melhor, e a ajuda está a caminho.',
 'O menino foi para a escola de ônibus.',
 'A casa do meu avô é linda.']
```

Tópicos avançados em PLN

Tradução automática

- Contextualização ✓
- Diversidade linguística ✓
- Estratégias ✓
- Avaliação ✓
- Recursos ✓
- Plus ✓
- Exemplo de código ✓
- **Considerações finais**

Tradução automática

Considerações finais

- Vieses e questões éticas
 - Viés de gênero
 - Geralmente o gênero masculino é atribuído quando se traduz de um idioma sem gênero marcado para um idioma que pede o gênero

The student went to school by bus.

O aluno foi para a escola de ônibus.

- Carrega estereótipos culturais

The nurse helped me.

A enfermeira me ajudou.

The doctor helped me.

O médico me ajudou.

Os vieses são amplificados pelos sistemas de TA (PRATES et al., 2019 apud JURAFSKY; MARTIN, 2025)

Tradução automática

Considerações finais

- Vieses e questões éticas
 - Viés de gênero
 - Os sistemas se saem pior quando são requisitados a traduzir sentenças que descrevem pessoas em papéis que fogem aos estereótipos (STANOVSKY et al., 2019 apud JURAFSKY; MARTIN, 2025)

The doctor asked the nurse to help her in the operation

O médico pediu à enfermeira que a ajudasse na operação

Tradução gerada pelo [Google Tradutor](#) em 06/06/2025

A médica pediu à enfermeira que a ajudasse na operação

Tradução gerada pelo [Google Tradutor](#) em 08/06/2026

Tradução automática

Considerações finais

- Vieses e questões éticas
 - Cobertura inadequada para culturas menos representadas nos *datasets*

Thanksgiving is a typical holiday in USA.

O Dia de Ação de Graças é um feriado típico nos EUA.

Festa junina é uma festa típica brasileira.

Festa junina is a typical Brazilian festival.

Tradução automática

Considerações finais

- Vieses e questões éticas
 - Atribuição de um grau de confiança nas traduções geradas também é uma estratégia importante para evitar que uma interpretação equivocada com base em uma tradução errada ocorra

Tópicos avançados em PLN – TA

Referências específicas desta aula

- [Capítulo 13](#) do livro de (JURAFSKY; MARTIN, 2025)
- [Capítulo 4 do Volume 3](#) do livro de PLN do BPLN
- Curso de Linguística Computacional da UFMG - Prof. Thiago Castro Ferreira:
 - https://www.youtube.com/playlist?list=PLLrIHSmC0Mw73a1t73DEjgGMPyu8Qs_sWT
- Curso de Lena Voita
 - https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html

Tópicos avançados em PLN – TA

Leituras sugeridas

- [Capítulo 13](#) do livro de (JURAFSKY; MARTIN, 2025)A
- [Capítulo 4 do Volume 3](#) do livro de PLN do BPLN
 - Até a seção 4.2
- Plus
 - Seção 4.3 do Capítulo 4 do Volume 3 do livro de PLN do BPLN

Links interessantes

- Moses: <https://www2.statmt.org/moses/>
- Seq2Seq: https://lena-voita.github.io/nlp_course/seq2seq_and_attention.html